作业 3 · 方向 A「同一批财报 → 问答知识库」· 一页结论

语料：10 家白酒公司 × 2024/2025 年报 = 20 份年报 PDF（巨潮 cninfo）→ 3,583 页 → 15,682 块（表格块 5,690，占 36%）**索引**：BM25（CJK 二元组）+ 向量（embedding-3）+ 字段命中，三路 RRF 融合**问答**：DeepSeek 只依据召回片段作答、逐条标出处**验收**：10 题逐题记录 + 原文直读基准表人工复核

一句话结论

知识库的质量上限在检索，不在模型：单公司事实题只要召回对了表块就能答对；跨公司题必须分层抽样，否则只会召回到一家；而答案里的「资料中未提及」往往是**没召回**，不能当成模型的诚实。

哪类题答得好，哪类翻车，为什么

题型	代表题	结果	原因
单公司 · 指标数字	茅台营收/净利、洋河合同负债	稳定答对	命中「主要会计数据」等表块，数字能逐字对上
单公司 · 口径细节	泸州老窖「高档酒类」	正确地答「未提及」	年报只有「中高档酒类」，不编口径比给近似值重要
跨公司 · 谁最高/谁最快	十家营收对比	答对（茅台最高、汾酒最快）	分层抽样：每家先各取 3 块再合并
跨公司 · 关键词扫描	谁提到国际化	结论对、清单有瑕疵	本质是「十家各扫一遍」，分层只保证召回不保证覆盖

四个翻车根因（按修复顺序，均实测）

1. **高频词稀释**：「茅台/营业收入/2025」在 15,682 块里到处都是，茅台营收题召回了「债券相关情况」页 → **先按公司/年份做实体过滤再排序**，池确定后把公司名从查询里剔掉（池内全是这家公司，公司名已无区分度）。
2. **RRF 把「名次」当「块下标」** → 等于给前 61 个下标发分，检索看着有序实则随机。
3. **问题指标名与年报口径对不上**（问「中高档产品收入占比」，年报写「中高档白酒」）→ 补第三路**「字段命中」**：把表格的行首指标名与列头抽成标签，问题里点到就优先给该表块。
4. **噪声块抢排名**：只有页眉的碎块因 BM25 长度归一化排前面（3,365 块）→ 标 noise 剔除（**不改块序**，否则已算好的向量全部错位）。

人工复核（结论以此为准）

10 题里 9 题实质正确（数字与原文直读基准逐条核对通过），1 题（Q10）结论对但清单组织有瑕疵；**模型考官误判 1 次**——迎驾贡酒「中高档白酒收入」在 MD&A 是 46.83 亿（合并口径）、在附注「合同分类」是 29.11 亿（另一口径），考官见到两个数就判错。**考官能抓逻辑矛盾，但不能替代人工核对口径。**

顺带的数据发现

2025 年白酒板块普跌：10 家里只有山西汾酒营收正增长（+7.52%），茅台 −1.21%、今世缘 −11.81%、洋河 −33.47%、口子窖 −33.65%、五粮液 −54.55%；净利跌幅普遍大于营收跌幅（茅台净利 −4.53%）。

交付：代码仓库 https://github.com/Yonder-Solivagant/financial-kb问答页截图 3 张10 题逐题记录（问答记录.md，含人工复核段）本页即「一页结论」